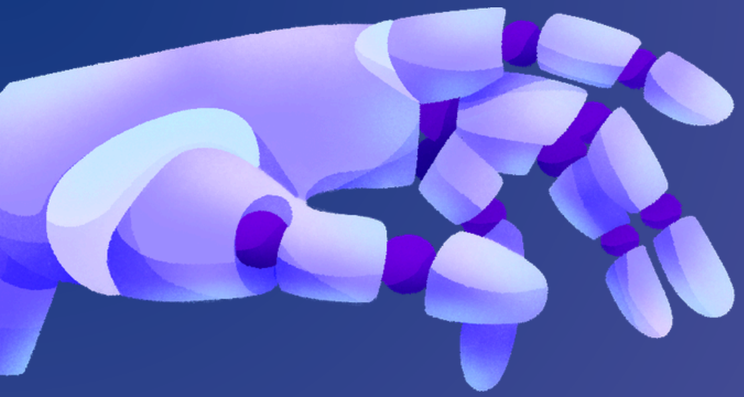


EVALUACIÓN 1:
CALIDAD Y PREPARACIÓN DE DATOS

INTEGRANTES: DANAE ACOSTA, JAVIERA MÁRQUEZ, NICOLÁS MONTES Y VICENTE PALMA
DOCENTE: JAZNA MEZA
ASIGNATURA: INTELIGENCIA ARTIFICIAL

Y ARQUITECTURA DEL ARCHIVO, ANTES DE TOCAR NADA

5.100 registros y 11 variables. Esto es lo que el diagnóstico encuentra.

5100

REGISTROS

11

VARIABLES

1335

FALTANTES

100

DUPLICADOS

129

INCONSISTENCIAS

DANAE

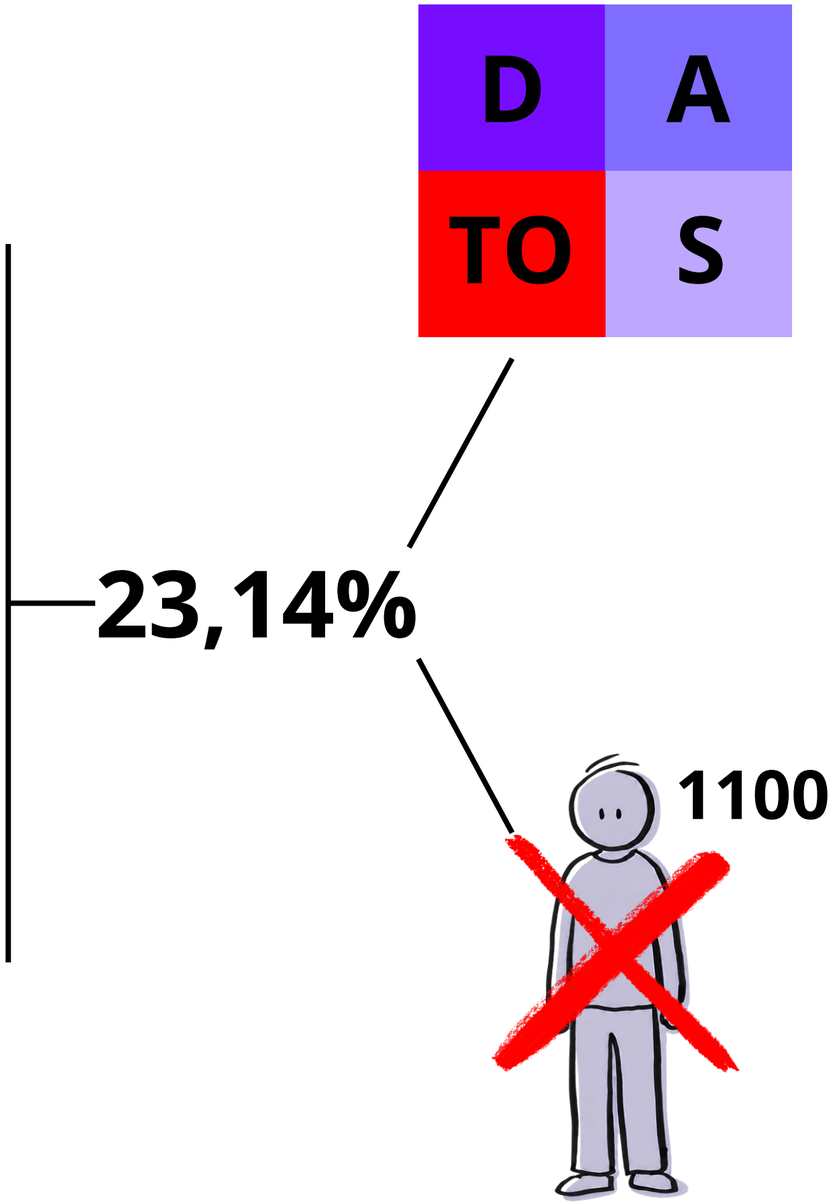
NULOS

DUPLICADOS

INCONSISTENCIAS

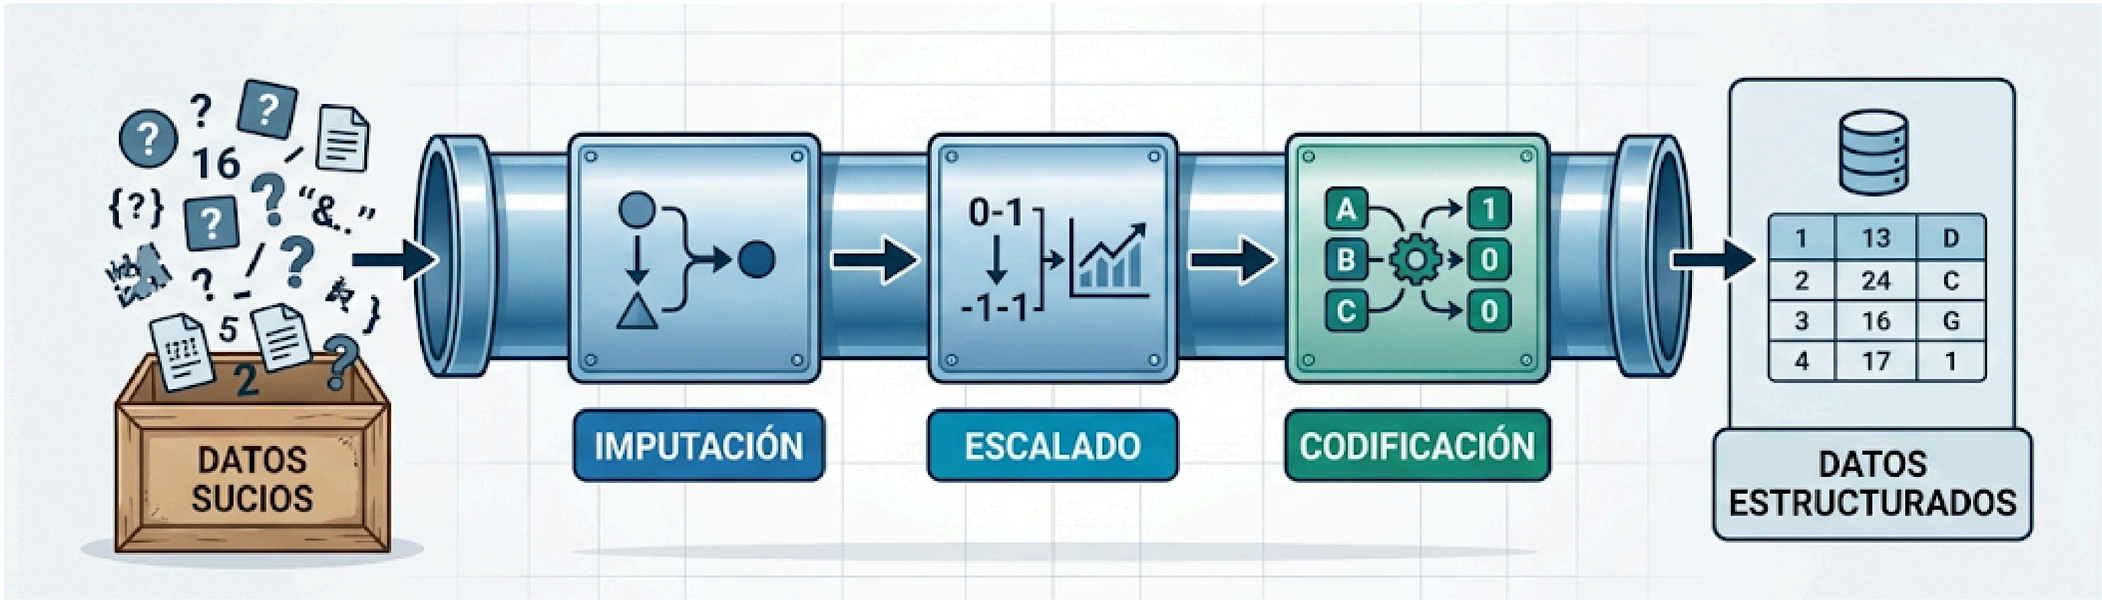
NULOS

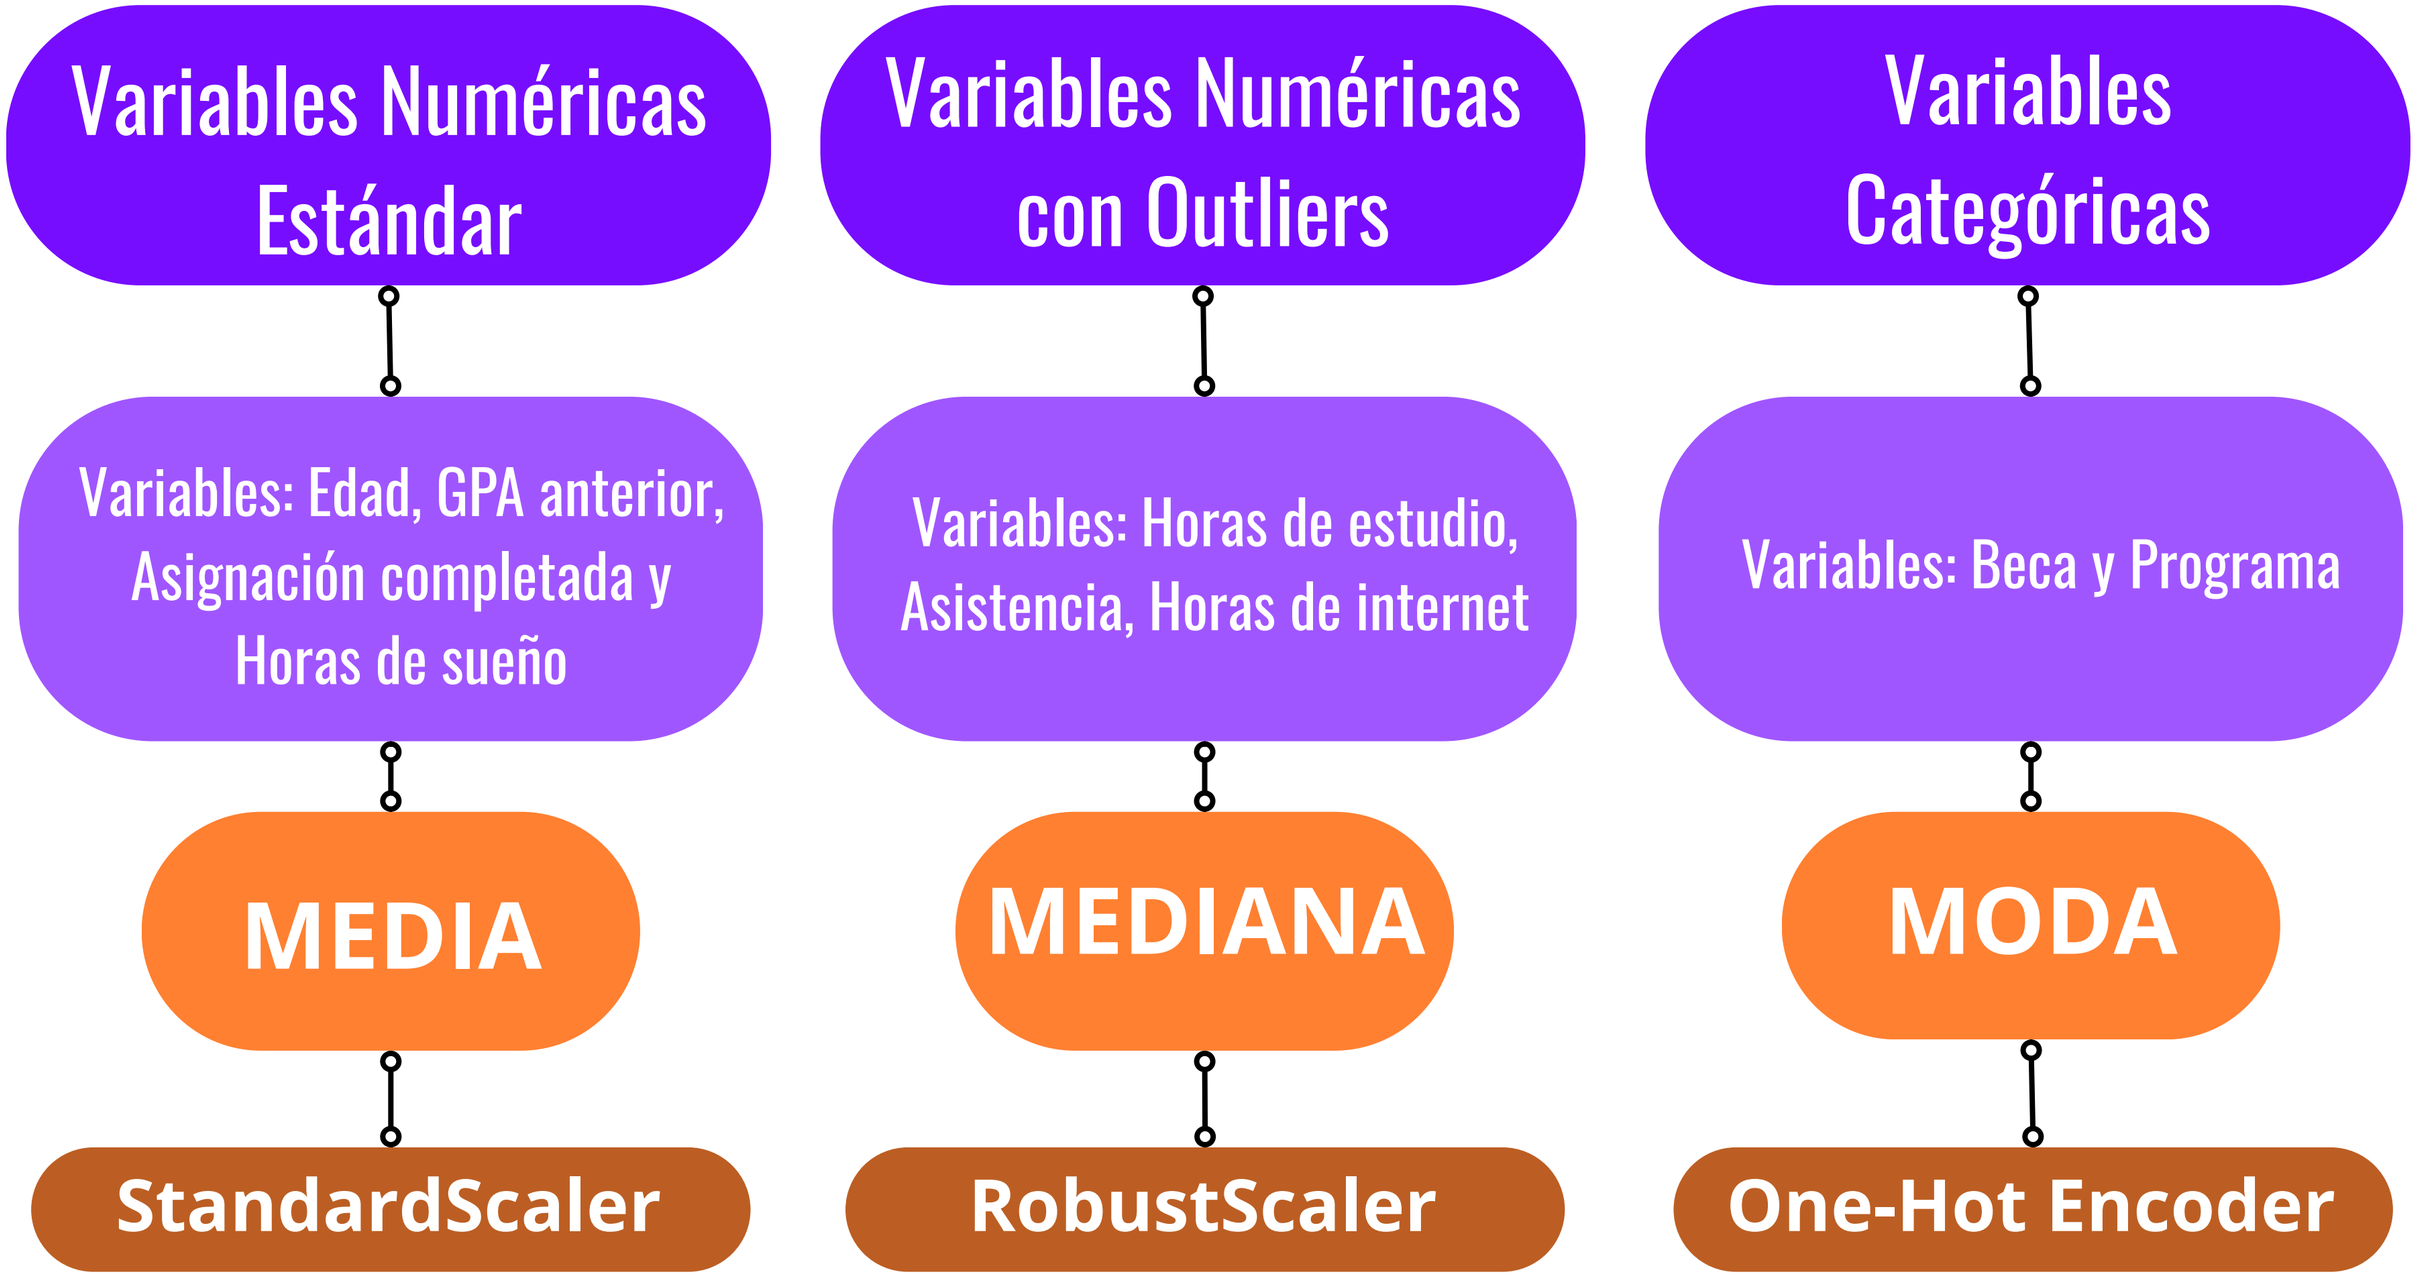
	Nulos	Porcentaje
Attendance	224	4.39
AssignmentsCompleted	216	4.24
StudyHours	181	3.55
InternetHours	176	3.45
PreviousGPA	162	3.18
SleepHours	122	2.39
Age	103	2.02
Scholarship	81	1.59
Program	70	1.37



PIPELINE

de Scikit-Learn




Variables Numéricas Estándar
Variables: Edad, GPA anterior, Asignación completada y Horas de sueño
MEDIA
StandardScaler
Variables Numéricas con Outliers
Variables: Horas de estudio, Asistencia, Horas de internet
MEDIANA
RobustScaler
Variables Categóricas
Variables: Beca y Programa
MODA
One-Hot Encoder

DUPLICADOS

100 filas repetidas (***1.96%*** del dataset)

StudentID: Coincidencia exacta

Error del sistema: Falla en carga masiva

Eliminación de copias

.drop_duplicates()

Evitamos ***Sesgo***

Reducimos registros

100 filas eliminadas

5.100 → ***5.000***

INCONSISTENCIAS

VARIABLES AFECTADAS

Scholarship (Beca) y ***Program*** (Carrera)

PROBLEMA

Múltiples variaciones de formato por digitación ***manual***

CAUSAS

Inconsistencias en mayúsculas, espacios y tildes

¿ Sí ≠ si ≠ Si ?

Estrategia de Limpieza

1. ***.str.strip()*** → Eliminar ***espacios***
2. ***.str.upper()*** → ***Mayúsculas*** uniformes
3. ***.replace()*** → ***Agrupación*** manual

Resultado

Variables Fragmentadas	*Acción*	*Etiqueta Única Correcta*
'SÍ', 'SI', 'si', 'SI '	→	'Sí'
'NO', 'no', 'NAN'	→	'No'
'INGENIERÍA INFORMÁTICA', 'Ingenieria Informatica'	→	'Ingeniería Informática'

INCONSISTENCIAS

¿Qué encontramos?

- Errores Numéricos (Límites Lógicos)
- Asistencias irreales (superiores al 100%).
- Notas finales fuera de la escala nacional (1.0 a 7.0).
- Horas de sueño con valores negativos.

Acotados con .clip().



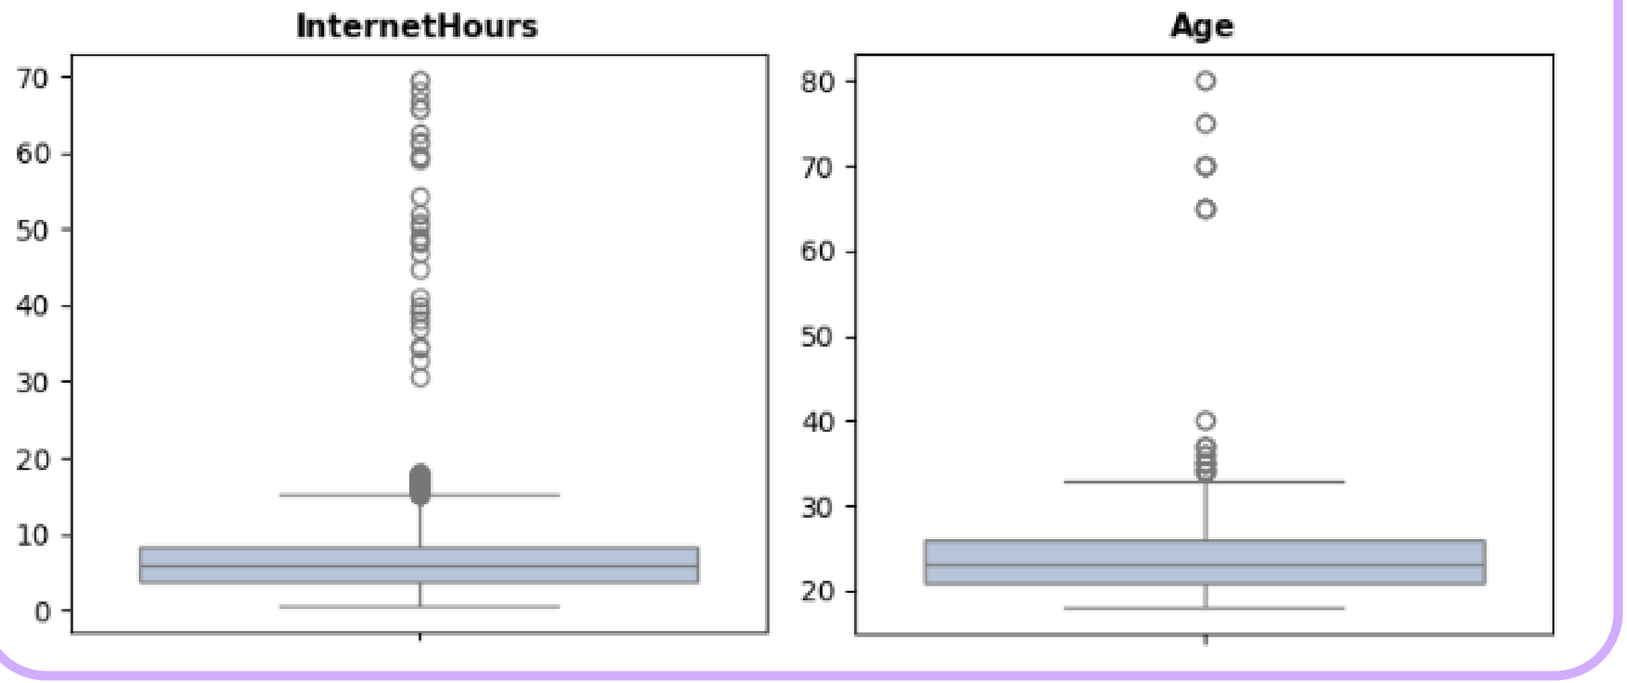
VALORES ATÍPICOS

Método: Regla del Rango Intercuartílico. Límites de detección:

Q1-1.5xIQR y Q3 + 1.5xIQR

¿Qué encontramos?

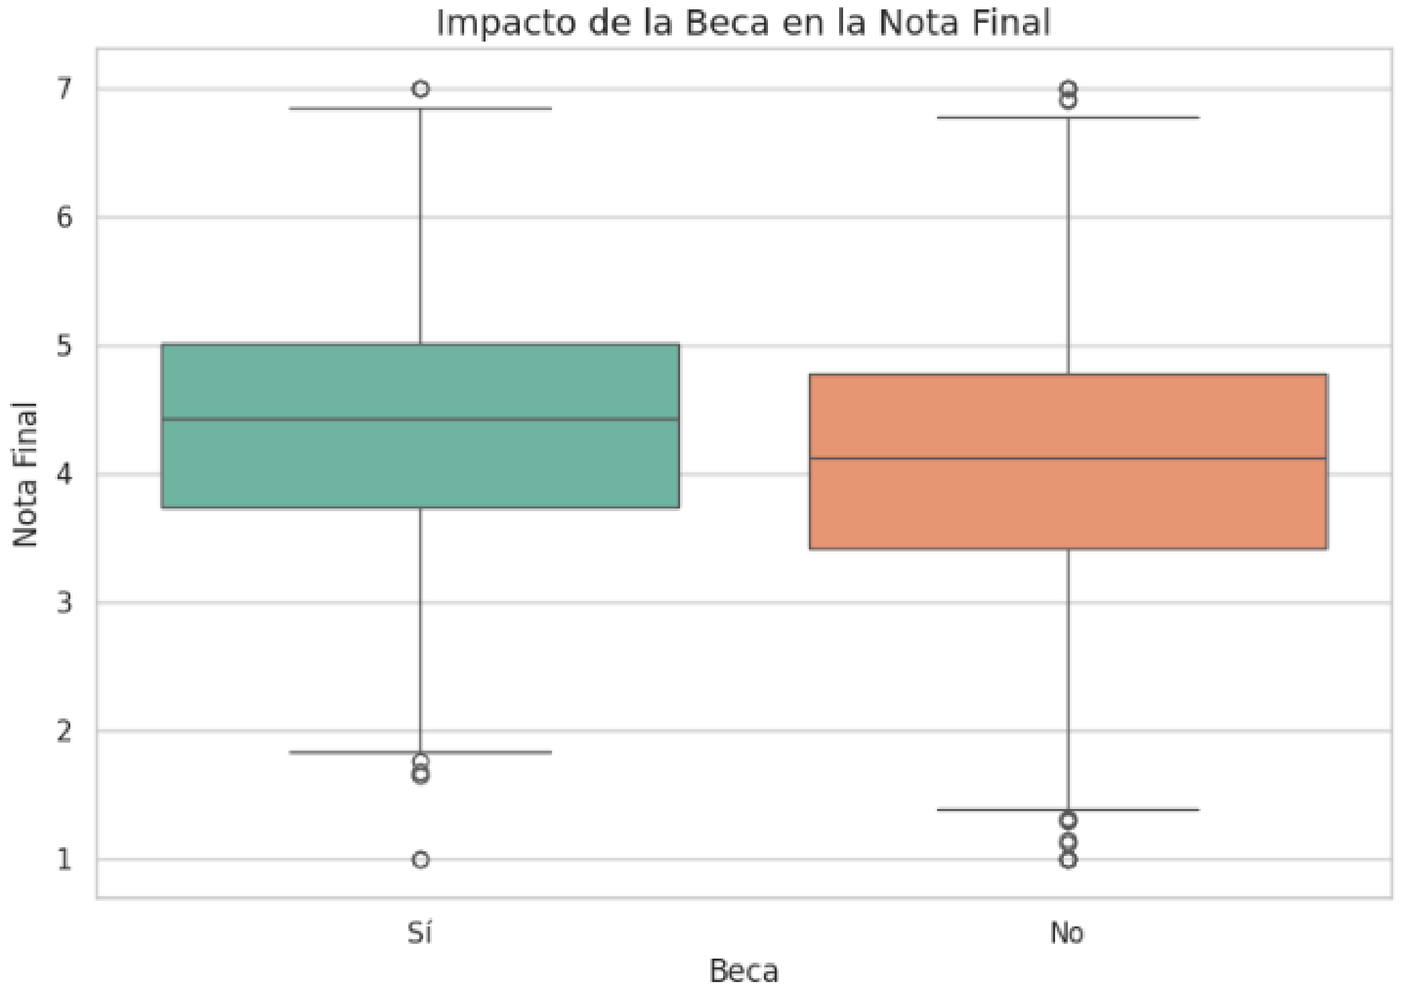
- Detectamos 393 valores distribuidos en 5 variables numéricas.
- Principalmente en Horas de Internet (145 casos) y Edad (63 casos).



RESULTADOS DEL EDA

Impacto Institucional (Beca vs. Rendimiento)

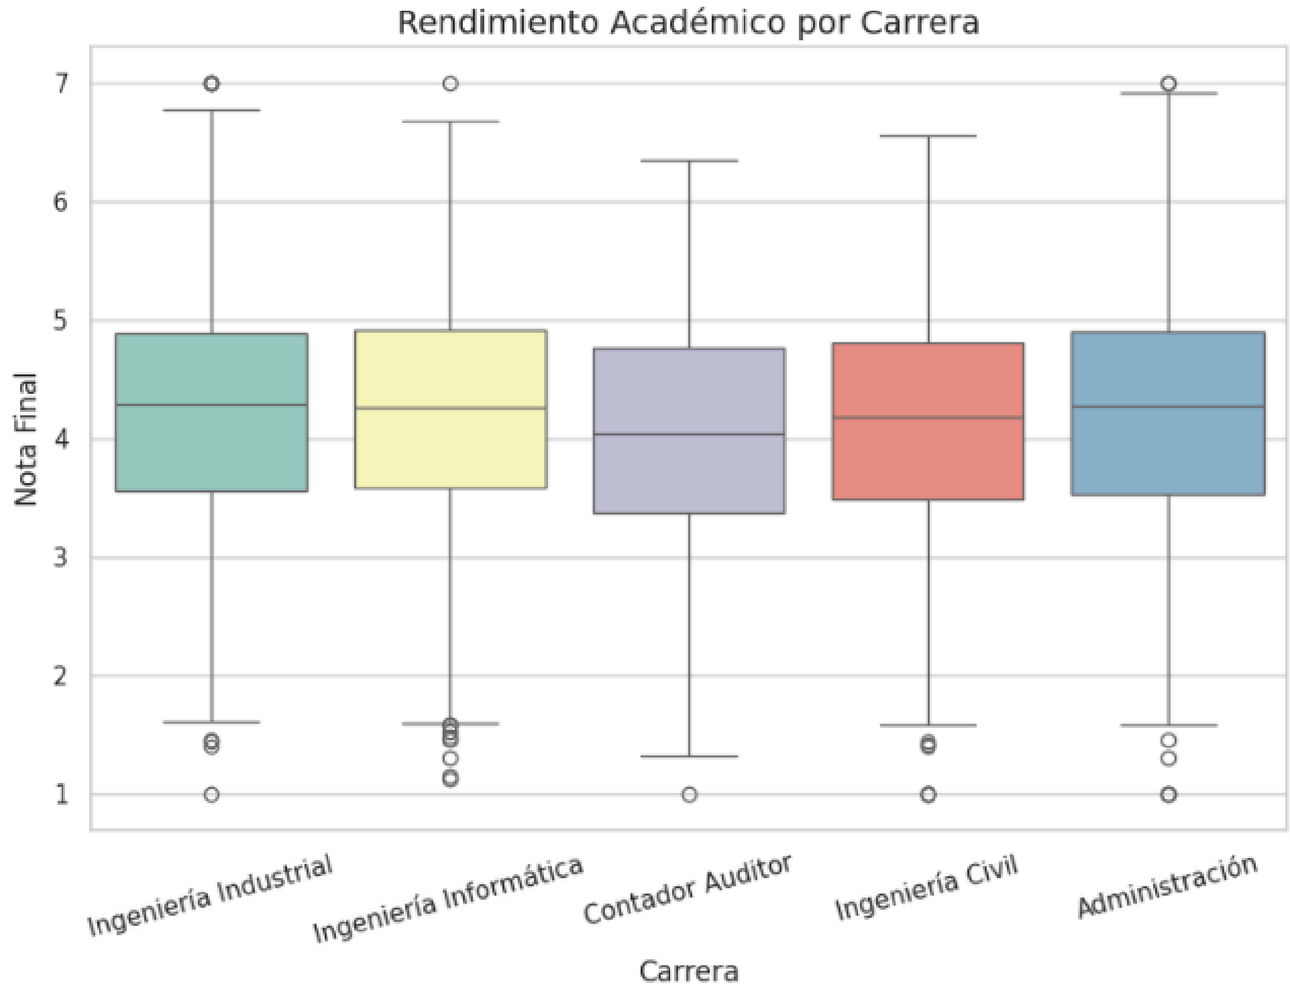
Rendimiento superior: La mediana de calificaciones es mayor en estudiantes becados (aprox. 4.37 vs 4.07).



RESULTADOS DEL EDA

Desempeño por Programa Académico

Líderes de rendimiento:
Ingeniería Industrial, Ingeniería Informática y Administración presentan las medianas más altas (aprox. 4.3).



RESULTADOS DEL EDA

Horas de Estudio

Tendencia positiva: Existe una relación directa confirmada estadísticamente por el Coeficiente de Pearson (r = 0.4920).

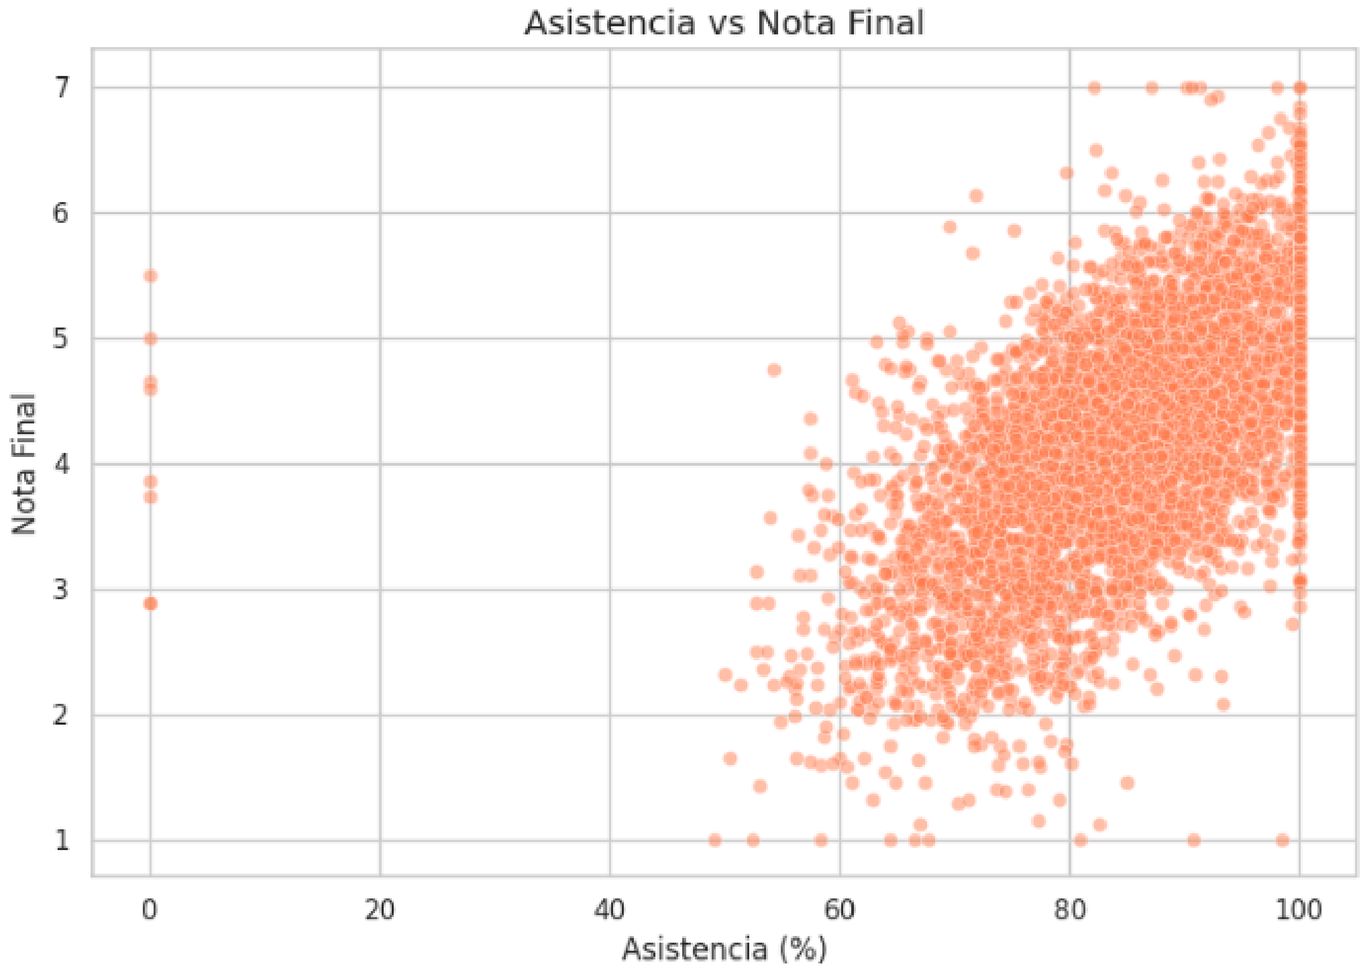
Comportamiento estándar: La mayor densidad de la población estudiantil se concentra dedicando entre 0 y 30 horas.



RESULTADOS DEL EDA

Asistencia Presencial

Correlación fuerte: Se evidencia gráficamente una relación ascendente muy marcada; a mayor presencialidad, mejores calificaciones.



PANDAS

Validación final de calidad: Comparativa del dataset original versus el dataset tratado

	Indicador	Dataset original	Dataset tratado
0	Cantidad de registros	5100	5000
1	Cantidad de variables	11	16
2	Valores faltantes	1335	0
3	Registros duplicados	100	0
4	Inconsistencias	Presentes (textos no estandarizados y rangos f...	Ninguna (unificadas, limpiadas y codificadas)
5	Outliers tratados	No tratados (valores atípicos detectados por IQR)	Tratados mediante pipeline y límites de domini...

Gracias por su Atención